

Asignatura 3.2 — Aprendizaje Automático y Aprendizaje Profundo Aplicados a Finanzas Corporativas

Banco de 30 preguntas de opción múltiple · una sola correcta · con justificación · en la app se sortean 15 por intento

Pregunta 1. Predecir si un cliente pagará o no (paga/no paga) es un problema de:

- A. Regresión.
- B. ☒ Clasificación supervisada.
- C. Clustering.
- D. Aprendizaje por refuerzo.

Justificación. Predecir una clase con datos etiquetados es clasificación supervisada. La regresión predice números; el clustering no usa etiquetas; el refuerzo aprende de recompensas.

Pregunta 2. El sobreajuste (overfitting) es:

- A. Cuando el modelo generaliza muy bien.
- B. ☒ Cuando el modelo memoriza el ruido del entrenamiento y falla en datos nuevos.
- C. Un tipo de gráfico.
- D. Falta de datos.

Justificación. Overfitting = ajustar el ruido en vez de la señal, con mal desempeño fuera de muestra. Es lo opuesto a generalizar bien.

Pregunta 3. ¿Por qué la exactitud (accuracy) sola engaña con la mora?

- A. Porque es difícil de calcular.
- B. ☒ Porque con clases desbalanceadas un modelo que dice “nadie cae” acierta mucho y es inútil.
- C. Porque no existe.
- D. Porque siempre da 100%.

Justificación. Si la mora es rara (3%), predecir “nadie cae” da 97% de exactitud pero no detecta a ningún moroso. Por eso se usan precisión, recall y AUC.

Pregunta 4. La función que convierte el score z en una probabilidad (0–1) en la regresión logística es:

- A. La raíz cuadrada.
- B. ☒ La sigmoide: $1/(1+e^{-z})$.
- C. El logaritmo.
- D. La media.

Justificación. La sigmoide mapea cualquier z real a $(0,1)$, interpretable como probabilidad. Las otras funciones no cumplen esa propiedad.

Pregunta 5. La validación cruzada sirve para:

- A. Aumentar los datos.
- B. ☒ Estimar el desempeño de forma robusta rotando el conjunto de validación.
- C. Entrenar más rápido.
- D. Eliminar variables.

Justificación. La validación cruzada rota qué datos se usan para validar, dando una estimación más estable del desempeño. No crea datos ni acelera el entrenamiento por sí sola.

Pregunta 6. El “data snooping” en finanzas consiste en:

- A. Ordenar los datos.
- B. ☒ Probar muchos modelos hasta que uno funciona por azar.
- C. Limpiar valores faltantes.
- D. Graficar series.

Justificación. Probar mil configuraciones y quedarse con la que “funcionó” genera falsos positivos por azar (López de Prado). No es ordenar ni limpiar datos.

Pregunta 7. El sesgo de anticipación (look-ahead bias) es:

- A. ☒ Usar información que no estaría disponible al momento de decidir.
- B. Predecir el pasado.
- C. Un tipo de regularización.
- D. Un gráfico de barras.

Justificación. Look-ahead bias = filtrar información futura en el entrenamiento, inflando el desempeño irrealmente. No es regularización ni un gráfico.

Pregunta 8. El AUC (área bajo la curva ROC) mide:

- A. El costo del modelo.
- B. ☒ La capacidad de ordenar el riesgo con independencia del umbral.

- C. La cantidad de variables.
- D. El tiempo de entrenamiento.

Justificación. El AUC evalúa qué tan bien el modelo ordena positivos sobre negativos sin fijar un umbral. No mide costo, cantidad de variables ni tiempo.

Pregunta 9. La elección del umbral de corte en un scoring de crédito es:

- A. Puramente técnica.
- B. ✓ Una decisión de negocio: depende del costo de un falso positivo vs. un falso negativo.
- C. Siempre 0,5.
- D. Irrelevante.

Justificación. El umbral balancea rechazar buenos clientes (FP) contra aprobar malos (FN); es una decisión de negocio, no un 0,5 universal.

Pregunta 10. En finanzas, ¿por qué importa la interpretabilidad del modelo?

- A. Por estética.
- B. ✓ Porque hay que explicar por qué se decide (ética, a veces regulación) y auditar el modelo.
- C. Porque los modelos simples son siempre mejores.
- D. No importa.

Justificación. Explicar una decisión de crédito es una exigencia ética y a menudo regulatoria; la caja negra es un pasivo. No es estética ni implica que lo simple siempre gane.

Pregunta 11. SHAP y la importancia de variables sirven para:

- A. Entrenar más rápido.
- B. ✓ Abrir la caja negra: mostrar cuánto pesa cada factor en la decisión.
- C. Borrar datos.
- D. Cambiar el umbral.

Justificación. Son técnicas de interpretabilidad que atribuyen la decisión a cada variable. No aceleran el entrenamiento ni borran datos.

Pregunta 12. El compromiso sesgo-varianza dice que:

- A. Más flexibilidad siempre es mejor.
- B. ✓ Modelos muy flexibles bajan el sesgo pero suben la varianza; hay un punto medio.
- C. El sesgo y la varianza son lo mismo.
- D. No existe.

Justificación. Aumentar la flexibilidad reduce el sesgo pero aumenta la varianza (y el sobreajuste); el arte está en equilibrarlos. No es que más flexibilidad siempre gane.

Pregunta 13. La “navaja de Occam financiera” sugiere:

- A. Usar siempre el modelo más complejo.
- B. **✓ Empezar por el modelo más simple que resuelva el problema.**
- C. No usar modelos.
- D. Elegir por moda.

Justificación. Preferir la simplicidad interpretable frente a la complejidad opaca que gana marginalmente. No es rechazar modelos ni seguir modas.

Pregunta 14. Un ensamble de árboles (random forest, gradient boosting) es:

- A. Un modelo lineal simple.
- B. **✓ Un modelo no lineal potente, típicamente menos interpretable que una regresión.**
- C. Una hoja de cálculo.
- D. Un tipo de gráfico.

Justificación. Los ensambles de árboles capturan no linealidades con gran poder predictivo, a costa de interpretabilidad. No son lineales ni un gráfico.

Pregunta 15. Según López de Prado, la principal causa de estrategias que fallan en producción es:

- A. Usar Excel.
- B. **✓ El backtest overfitting (validar mal, dando falsa confianza).**
- C. Tener demasiados datos.
- D. La interpretabilidad.

Justificación. Validar mal produce backtests brillantes y modelos inútiles: es la causa central de fracasos. No se debe a Excel, al exceso de datos ni a explicar el modelo.

Pregunta 16. Segmentar clientes sin etiquetas previas es un problema de:

- A. Clasificación supervisada.
- B. **✓ Aprendizaje no supervisado (clustering).**
- C. Regresión.
- D. Refuerzo.

Justificación. El clustering agrupa sin etiquetas: es aprendizaje no supervisado. La clasificación y la regresión son supervisadas.

Pregunta 17. Predecir la demanda (un número) es un problema de:

- A. Clasificación.
- B. ✓ Regresión.
- C. Clustering.
- D. Refuerzo.

Justificación. Predecir un valor numérico continuo es regresión. La clasificación predice clases; el clustering no usa etiquetas.

Pregunta 18. La regularización sirve para:

- A. Aumentar el sobreajuste.
- B. ✓ Penalizar la complejidad del modelo y combatir el sobreajuste.
- C. Borrar datos.
- D. Acelerar la GPU.

Justificación. La regularización penaliza modelos demasiado complejos, reduciendo el sobreajuste. No borra datos ni es un tema de hardware.

Pregunta 19. La partición en entrenamiento, validación y prueba busca:

- A. Tener más datos.
- B. ✓ Evaluar el modelo con datos que no vio y evitar el autoengaño.
- C. Entrenar más rápido.
- D. Eliminar variables.

Justificación. Separar los datos permite ajustar (train), elegir hiperparámetros (validación) y medir honestamente (test) con datos no vistos.

Pregunta 20. La precisión (precision) de un clasificador es:

- A. $VP/(VP+FN)$.
- B. ✓ $VP/(VP+FP)$.
- C. $VN/(VN+FP)$.
- D. $VP/Total$.

Justificación. Precisión = $VP/(VP+FP)$; de lo que predijo positivo, cuánto lo era. $VP/(VP+FN)$ es el recall.

Pregunta 21. El recall (sensibilidad) es:

- A. $VP/(VP+FP)$.

- B. ✓ $VP/(VP+FN)$.
- C. $FP/(FP+VN)$.
- D. $VN/Total$.

Justificación. Recall = $VP/(VP+FN)$; de los positivos reales, cuántos detectó. Es clave con clases raras como la mora.

Pregunta 22. En un scoring de crédito, un falso positivo significa:

- A. Aprobar a un cliente que no paga.
- B. ✓ Rechazar a un cliente que sí pagaría (buen cliente).
- C. Acertar.
- D. No decidir.

Justificación. Si “positivo” es riesgo/rechazo, un falso positivo es rechazar a un buen cliente: costo de oportunidad. El falso negativo es aprobar a uno malo.

Pregunta 23. El “feature engineering” es:

- A. Entrenar el modelo.
- B. ✓ Construir y transformar las variables (features) que alimentan el modelo.
- C. Graficar resultados.
- D. Elegir el color.

Justificación. El feature engineering crea las variables informativas a partir de los datos crudos; suele pesar más que el algoritmo elegido.

Pregunta 24. En el scoring del caso, MMULT se usa para:

- A. Ordenar clientes.
- B. ✓ Multiplicar la matriz de features por el vector de coeficientes (el score z).
- C. Borrar filas.
- D. Formatear celdas.

Justificación. $z = X \cdot \beta$ se calcula con MMULT (features $\times$ coeficientes); luego la sigmoide lo convierte en probabilidad.

Pregunta 25. Un modelo de crédito debe poder explicar por qué rechaza a un cliente porque:

- A. Es opcional.
- B. ✓ Lo exige la ética y a menudo la regulación.
- C. Mejora la GPU.

D. Reduce el AUC.

Justificación. La explicabilidad de una decisión de crédito es una exigencia ética y regulatoria; la caja negra es un pasivo.

Pregunta 26. El aprendizaje profundo (deep learning) es especialmente útil para:

- A. Problemas triviales.
- B. ✓ Patrones complejos y datos no estructurados (imágenes, texto).
- C. Sumar dos números.
- D. Nada.

Justificación. Las redes profundas capturan patrones complejos y datos no estructurados, a costa de interpretabilidad y datos. No se justifican para lo trivial.

Pregunta 27. El aprendizaje por refuerzo aprende de:

- A. Etiquetas fijas.
- B. ✓ La interacción con un entorno mediante recompensas.
- C. Clustering.
- D. Regresión.

Justificación. El refuerzo optimiza acciones según recompensas del entorno. Es menos frecuente en finanzas corporativas.

Pregunta 28. La curva ROC relaciona:

- A. Ventas y costos.
- B. ✓ La tasa de verdaderos positivos con la de falsos positivos a distintos umbrales.
- C. Activo y pasivo.
- D. Precio y volumen.

Justificación. La ROC traza TPR vs FPR variando el umbral; el área bajo ella (AUC) resume la capacidad de ordenar el riesgo.

Pregunta 29. Según Géron, la mayor parte del trabajo real de un proyecto de ML es:

- A. Elegir el algoritmo de moda.
- B. ✓ La preparación de datos y la validación honesta.
- C. Comprar GPUs.
- D. Hacer gráficos.

Justificación. La disciplina del proceso (datos + validación) pesa mucho más que el algoritmo de moda. Es donde se juega el resultado.

Pregunta 30. Con clases desbalanceadas (mora rara), conviene mirar:

- A. Solo la exactitud.
- B. ✓ Precisión, recall y AUC, además de la exactitud.
- C. Solo el color.
- D. Nada.

Justificación. La exactitud engaña con clases raras; precisión, recall y AUC dan una imagen honesta del desempeño.