

Asignatura 3.2 — Aprendizaje Automático y Aprendizaje Profundo Aplicados a Finanzas Corporativas

15 preguntas de opción múltiple · una sola correcta · con justificación

Pregunta 1. Predecir si un cliente pagará o no (paga/no paga) es un problema de:

- A. Regresión.
- B. ☒ Clasificación supervisada.
- C. Clustering.
- D. Aprendizaje por refuerzo.

Justificación. Predecir una clase con datos etiquetados es clasificación supervisada. La regresión predice números; el clustering no usa etiquetas; el refuerzo aprende de recompensas.

Pregunta 2. El sobreajuste (overfitting) es:

- A. Cuando el modelo generaliza muy bien.
- B. ☒ Cuando el modelo memoriza el ruido del entrenamiento y falla en datos nuevos.
- C. Un tipo de gráfico.
- D. Falta de datos.

Justificación. Overfitting = ajustar el ruido en vez de la señal, con mal desempeño fuera de muestra. Es lo opuesto a generalizar bien.

Pregunta 3. ¿Por qué la exactitud (accuracy) sola engaña con la mora?

- A. Porque es difícil de calcular.
- B. ☒ Porque con clases desbalanceadas un modelo que dice “nadie cae” acierta mucho y es inútil.
- C. Porque no existe.
- D. Porque siempre da 100%.

Justificación. Si la mora es rara (3%), predecir “nadie cae” da 97% de exactitud pero no detecta a ningún moroso. Por eso se usan precisión, recall y AUC.

Pregunta 4. La función que convierte el score z en una probabilidad (0–1) en la regresión logística es:

- A. La raíz cuadrada.
- B. ☒ La sigmoide: $1/(1+e^{-z})$.
- C. El logaritmo.
- D. La media.

Justificación. La sigmoide mapea cualquier z real a $(0,1)$, interpretable como probabilidad. Las otras funciones no cumplen esa propiedad.

Pregunta 5. La validación cruzada sirve para:

- A. Aumentar los datos.
- B. ☒ Estimar el desempeño de forma robusta rotando el conjunto de validación.
- C. Entrenar más rápido.
- D. Eliminar variables.

Justificación. La validación cruzada rota qué datos se usan para validar, dando una estimación más estable del desempeño. No crea datos ni acelera el entrenamiento por sí sola.

Pregunta 6. El “data snooping” en finanzas consiste en:

- A. Ordenar los datos.
- B. ☒ Probar muchos modelos hasta que uno funciona por azar.
- C. Limpiar valores faltantes.
- D. Graficar series.

Justificación. Probar mil configuraciones y quedarse con la que “funcionó” genera falsos positivos por azar (López de Prado). No es ordenar ni limpiar datos.

Pregunta 7. El sesgo de anticipación (look-ahead bias) es:

- A. ☒ Usar información que no estaría disponible al momento de decidir.
- B. Predecir el pasado.
- C. Un tipo de regularización.
- D. Un gráfico de barras.

Justificación. Look-ahead bias = filtrar información futura en el entrenamiento, inflando el desempeño irrealmente. No es regularización ni un gráfico.

Pregunta 8. El AUC (área bajo la curva ROC) mide:

- A. El costo del modelo.
- B. ☒ La capacidad de ordenar el riesgo con independencia del umbral.

- C. La cantidad de variables.
- D. El tiempo de entrenamiento.

Justificación. El AUC evalúa qué tan bien el modelo ordena positivos sobre negativos sin fijar un umbral. No mide costo, cantidad de variables ni tiempo.

Pregunta 9. La elección del umbral de corte en un scoring de crédito es:

- A. Puramente técnica.
- B. ☒ Una decisión de negocio: depende del costo de un falso positivo vs. un falso negativo.
- C. Siempre 0,5.
- D. Irrelevante.

Justificación. El umbral balancea rechazar buenos clientes (FP) contra aprobar malos (FN); es una decisión de negocio, no un 0,5 universal.

Pregunta 10. En finanzas, ¿por qué importa la interpretabilidad del modelo?

- A. Por estética.
- B. ☒ Porque hay que explicar por qué se decide (ética, a veces regulación) y auditar el modelo.
- C. Porque los modelos simples son siempre mejores.
- D. No importa.

Justificación. Explicar una decisión de crédito es una exigencia ética y a menudo regulatoria; la caja negra es un pasivo. No es estética ni implica que lo simple siempre gane.

Pregunta 11. SHAP y la importancia de variables sirven para:

- A. Entrenar más rápido.
- B. ☒ Abrir la caja negra: mostrar cuánto pesa cada factor en la decisión.
- C. Borrar datos.
- D. Cambiar el umbral.

Justificación. Son técnicas de interpretabilidad que atribuyen la decisión a cada variable. No aceleran el entrenamiento ni borran datos.

Pregunta 12. El compromiso sesgo-varianza dice que:

- A. Más flexibilidad siempre es mejor.
- B. ☒ Modelos muy flexibles bajan el sesgo pero suben la varianza; hay un punto medio.
- C. El sesgo y la varianza son lo mismo.
- D. No existe.

Justificación. Aumentar la flexibilidad reduce el sesgo pero aumenta la varianza (y el sobreajuste); el arte está en equilibrarlos. No es que más flexibilidad siempre gane.

Pregunta 13. La “navaja de Occam financiera” sugiere:

- A. Usar siempre el modelo más complejo.
- B. **✓ Empezar por el modelo más simple que resuelva el problema.**
- C. No usar modelos.
- D. Elegir por moda.

Justificación. Preferir la simplicidad interpretable frente a la complejidad opaca que gana marginalmente. No es rechazar modelos ni seguir modas.

Pregunta 14. Un ensamble de árboles (random forest, gradient boosting) es:

- A. Un modelo lineal simple.
- B. **✓ Un modelo no lineal potente, típicamente menos interpretable que una regresión.**
- C. Una hoja de cálculo.
- D. Un tipo de gráfico.

Justificación. Los ensambles de árboles capturan no linealidades con gran poder predictivo, a costa de interpretabilidad. No son lineales ni un gráfico.

Pregunta 15. Según López de Prado, la principal causa de estrategias que fallan en producción es:

- A. Usar Excel.
- B. **✓ El backtest overfitting (validar mal, dando falsa confianza).**
- C. Tener demasiados datos.
- D. La interpretabilidad.

Justificación. Validar mal produce backtests brillantes y modelos inútiles: es la causa central de fracasos. No se debe a Excel, al exceso de datos ni a explicar el modelo.