

## Asignatura 3.2 — Aprendizaje Automático y Aprendizaje Profundo Aplicados a Finanzas Corporativas

*Banco de 15 preguntas de opción múltiple · una sola correcta · con justificación · en la app se sortean 15 por intento*

**Pregunta 1.** Predecir si un cliente pagará o no (paga/no paga) es un problema de:

- A. Regresión.
- B. ☒ Clasificación supervisada.
- C. Clustering.
- D. Aprendizaje por refuerzo.

**Justificación.** Predecir una clase con datos etiquetados es clasificación supervisada. La regresión predice números; el clustering no usa etiquetas; el refuerzo aprende de recompensas.

**Pregunta 2.** El sobreajuste (overfitting) es:

- A. Cuando el modelo generaliza muy bien.
- B. ☒ Cuando el modelo memoriza el ruido del entrenamiento y falla en datos nuevos.
- C. Un tipo de gráfico.
- D. Falta de datos.

**Justificación.** Overfitting = ajustar el ruido en vez de la señal, con mal desempeño fuera de muestra. Es lo opuesto a generalizar bien.

**Pregunta 3.** ¿Por qué la exactitud (accuracy) sola engaña con la mora?

- A. Porque es difícil de calcular.
- B. ☒ Porque con clases desbalanceadas un modelo que dice “nadie cae” acierta mucho y es inútil.
- C. Porque no existe.
- D. Porque siempre da 100%.

**Justificación.** Si la mora es rara (3%), predecir “nadie cae” da 97% de exactitud pero no detecta a ningún moroso. Por eso se usan precisión, recall y AUC.

**Pregunta 4.** La función que convierte el score  $z$  en una probabilidad (0–1) en la regresión logística es:

- A. La raíz cuadrada.
- B. ☒ La sigmoide:  $1/(1+e^{-z})$ .
- C. El logaritmo.
- D. La media.

**Justificación.** La sigmoide mapea cualquier  $z$  real a  $(0,1)$ , interpretable como probabilidad. Las otras funciones no cumplen esa propiedad.

**Pregunta 5.** La validación cruzada sirve para:

- A. Aumentar los datos.
- B. ☒ Estimar el desempeño de forma robusta rotando el conjunto de validación.
- C. Entrenar más rápido.
- D. Eliminar variables.

**Justificación.** La validación cruzada rota qué datos se usan para validar, dando una estimación más estable del desempeño. No crea datos ni acelera el entrenamiento por sí sola.

**Pregunta 6.** El “data snooping” en finanzas consiste en:

- A. Ordenar los datos.
- B. ☒ Probar muchos modelos hasta que uno funciona por azar.
- C. Limpiar valores faltantes.
- D. Graficar series.

**Justificación.** Probar mil configuraciones y quedarse con la que “funcionó” genera falsos positivos por azar (López de Prado). No es ordenar ni limpiar datos.

**Pregunta 7.** El sesgo de anticipación (look-ahead bias) es:

- A. ☒ Usar información que no estaría disponible al momento de decidir.
- B. Predecir el pasado.
- C. Un tipo de regularización.
- D. Un gráfico de barras.

**Justificación.** Look-ahead bias = filtrar información futura en el entrenamiento, inflando el desempeño irrealmente. No es regularización ni un gráfico.

**Pregunta 8.** El AUC (área bajo la curva ROC) mide:

- A. El costo del modelo.
- B. ☒ La capacidad de ordenar el riesgo con independencia del umbral.

- C. La cantidad de variables.
- D. El tiempo de entrenamiento.

**Justificación.** El AUC evalúa qué tan bien el modelo ordena positivos sobre negativos sin fijar un umbral. No mide costo, cantidad de variables ni tiempo.

**Pregunta 9.** La elección del umbral de corte en un scoring de crédito es:

- A. Puramente técnica.
- B. ✓ Una decisión de negocio: depende del costo de un falso positivo vs. un falso negativo.
- C. Siempre 0,5.
- D. Irrelevante.

**Justificación.** El umbral balancea rechazar buenos clientes (FP) contra aprobar malos (FN); es una decisión de negocio, no un 0,5 universal.

**Pregunta 10.** En finanzas, ¿por qué importa la interpretabilidad del modelo?

- A. Por estética.
- B. ✓ Porque hay que explicar por qué se decide (ética, a veces regulación) y auditar el modelo.
- C. Porque los modelos simples son siempre mejores.
- D. No importa.

**Justificación.** Explicar una decisión de crédito es una exigencia ética y a menudo regulatoria; la caja negra es un pasivo. No es estética ni implica que lo simple siempre gane.

**Pregunta 11.** SHAP y la importancia de variables sirven para:

- A. Entrenar más rápido.
- B. ✓ Abrir la caja negra: mostrar cuánto pesa cada factor en la decisión.
- C. Borrar datos.
- D. Cambiar el umbral.

**Justificación.** Son técnicas de interpretabilidad que atribuyen la decisión a cada variable. No aceleran el entrenamiento ni borran datos.

**Pregunta 12.** El compromiso sesgo-varianza dice que:

- A. Más flexibilidad siempre es mejor.
- B. ✓ Modelos muy flexibles bajan el sesgo pero suben la varianza; hay un punto medio.
- C. El sesgo y la varianza son lo mismo.
- D. No existe.

**Justificación.** Aumentar la flexibilidad reduce el sesgo pero aumenta la varianza (y el sobreajuste); el arte está en equilibrarlos. No es que más flexibilidad siempre gane.

**Pregunta 13.** La “navaja de Occam financiera” sugiere:

- A. Usar siempre el modelo más complejo.
- B. **✓ Empezar por el modelo más simple que resuelva el problema.**
- C. No usar modelos.
- D. Elegir por moda.

**Justificación.** Preferir la simplicidad interpretable frente a la complejidad opaca que gana marginalmente. No es rechazar modelos ni seguir modas.

**Pregunta 14.** Un ensamble de árboles (random forest, gradient boosting) es:

- A. Un modelo lineal simple.
- B. **✓ Un modelo no lineal potente, típicamente menos interpretable que una regresión.**
- C. Una hoja de cálculo.
- D. Un tipo de gráfico.

**Justificación.** Los ensambles de árboles capturan no linealidades con gran poder predictivo, a costa de interpretabilidad. No son lineales ni un gráfico.

**Pregunta 15.** Según López de Prado, la principal causa de estrategias que fallan en producción es:

- A. Usar Excel.
- B. **✓ El backtest overfitting (validar mal, dando falsa confianza).**
- C. Tener demasiados datos.
- D. La interpretabilidad.

**Justificación.** Validar mal produce backtests brillantes y modelos inútiles: es la causa central de fracasos. No se debe a Excel, al exceso de datos ni a explicar el modelo.