



CONSULTING

Géron · Hastie/Tibshirani · López de Prado

Asignatura 3.2

Aprendizaje Automático y Aprendizaje Profundo Aplicados a Finanzas Corporativas

Aplicar aprendizaje automático a problemas de finanzas corporativas —predicción de mora, demanda y quiebra— con conciencia de sus supuestos, del sobreajuste y de la exigencia de interpretabilidad que impone la decisión financiera.

PREDICTIVA

36 h · 14 teóricas / 22 prácticas

Cuatrimestre 3

Correlativa: 1.3 · Tercer cuatrimestre

Objetivos de aprendizaje

- Distinguir aprendizaje supervisado, no supervisado y por refuerzo, y elegir el modelo según el problema.
- Entrenar y validar modelos evitando el sobreajuste, con partición y validación cruzada.
- Evaluar clasificadores con las métricas correctas (matriz de confusión, AUC, precisión/recall).
- Exigir interpretabilidad: en finanzas, un modelo que no se puede explicar no se puede usar para decidir.

01 El mapa del aprendizaje automático

Antes del algoritmo, el tipo de problema. La elección del modelo se deriva de la pregunta, no de la moda.

- **Supervisado:** se aprende de ejemplos etiquetados. Regresión (predecir un número: demanda, ventas) y clasificación (predecir una clase: paga / no paga).
- **No supervisado:** se buscan estructuras sin etiquetas. Segmentación de clientes (clustering), detección de anomalías (fraude).
- **Por refuerzo:** se aprende de la interacción con un entorno mediante recompensas. Menos frecuente en finanzas corporativas.

Los modelos van de los **lineales** (regresión logística, interpretable y robusta) a los **ensambles de árboles** (random forest, *gradient boosting* como XGBoost, potentes y no lineales) y las **redes neuronales** (aprendizaje profundo, para patrones complejos y datos no estructurados).

IDEA CLAVE La navaja de Occam financiera: empezá por el modelo más simple que resuelva el problema. Un modelo lineal interpretable que un directorio entiende suele ser preferible a un ensamble opaco que gana 1 % de precisión y nadie puede explicar.

02 Entrenar sin engañarse: sobreajuste y validación

El pecado capital del aprendizaje automático es memorizar en lugar de aprender.

- **Partición** en entrenamiento, validación y prueba. El modelo nunca se evalúa con datos que vio.
- **Sobreajuste (overfitting):** el modelo memoriza el ruido del entrenamiento y falla en datos nuevos. Se combate con **regularización** y modelos más simples.

- **Validación cruzada:** rotar el conjunto de validación para una estimación robusta del desempeño.

ATENCIÓN En finanzas hay un sobreajuste especialmente traicionero: el **sesgo de anticipación** (usar información que no estaría disponible al momento de decidir) y el **data snooping** (probar mil modelos hasta que uno “funciona” por azar). López de Prado documenta cómo estos errores producen backtests brillantes y modelos inútiles.

03 Evaluar un clasificador

La exactitud (accuracy) sola miente, sobre todo con clases desbalanceadas como la mora.

MATRIZ DE CONFUSIÓN

$$VP \cdot FP \cdot FN \cdot VN \rightarrow \text{Precisión} = VP / (VP + FP) \cdot \text{Recall} = VP / (VP + FN)$$

VP verdaderos positivos · FP falsos positivos · FN falsos negativos · VN verdaderos negativos

Si solo el 3 % de los clientes cae en mora, un modelo que dice “nadie cae” acierta el 97 %... y es inútil. Por eso se miran precisión, recall y AUC.

El **AUC** (área bajo la curva ROC) mide la capacidad de ordenar el riesgo con independencia del umbral. La elección del **umbral de corte** es una decisión de negocio: depende del costo de un falso positivo (rechazar a un buen cliente) frente al de un falso negativo (aprobar a uno que no paga).

04 Interpretabilidad y gobierno del modelo

En finanzas, la caja negra es un pasivo. Explicar por qué el modelo decide es parte del producto.

Técnicas como **SHAP** e **importancia de variables** abren la caja negra: muestran cuánto pesa cada factor en cada decisión. Un modelo de crédito debe poder explicar por qué rechazó a un cliente —lo exige la ética, y muchas veces la regulación—.

La mayoría de los descubrimientos en finanzas cuantitativas son falsos positivos. El rigor — validación adecuada, control del data snooping, comprensión del modelo— es lo que separa la ciencia del autoengaño.

— Marcos López de Prado. *Advances in Financial Machine Learning*

IDEA CLAVE La conexión con el resto del programa: la red neuronal se construyó a mano en Excel (2.3) para desmitificarla; acá se usa en serio, pero con la misma disciplina de auditar y explicar. La potencia sin interpretabilidad no es un activo en finanzas: es un riesgo.

05 El zoológico de modelos: de lo lineal a lo profundo

Elegir el modelo es elegir un lugar en el compromiso entre potencia e interpretabilidad. Conocer el menú evita usar un bazooka para matar una mosca —o al revés—.

Modelos y su compromiso

Familia	Potencia	Interpretabilidad
Regresión lineal / logística	Baja–media	Alta (cada coeficiente se lee)
Árboles de decisión	Media	Alta (reglas explícitas)
Random Forest	Alta	Media (importancia de variables)
Gradient Boosting (XGBoost)	Muy alta	Media–baja (requiere SHAP)
Redes neuronales (deep learning)	Máxima (datos no estructurados)	Baja (caja negra)

La navaja de Occam financiera: empezá por el modelo más simple que resuelva el problema. Un modelo lineal interpretable que el directorio entiende suele ser preferible a un ensamble opaco que gana 1 % de precisión y nadie puede explicar.

El **compromiso sesgo-varianza** guía la elección: modelos muy flexibles (redes profundas) reducen el sesgo pero disparan la varianza (sobreajuste); modelos simples (lineales) tienen más sesgo pero generalizan mejor con pocos datos. En finanzas corporativas —donde los datos suelen ser escasos y ruidosos— la simplicidad interpretable suele ganar.

La flexibilidad de un modelo es un arma de doble filo: reduce el error en los datos que ya viste y lo aumenta en los nuevos. El arte de la estadística es encontrar el punto de equilibrio.

— **Trevor Hastie & Robert Tibshirani.** *The Elements of Statistical Learning*

06 Validar sin engañarse: el pecado capital del ML financiero

En finanzas, validar mal es peor que no validar: da falsa confianza. Los errores de validación producen modelos que brillan en el backtest y fracasan en producción.

- **Sesgo de anticipación (look-ahead bias):** usar información que no estaría disponible al momento de decidir. Un modelo que "predice" la mora usando datos que solo se conocen después es inútil en la práctica.
- **Data snooping:** probar mil modelos hasta que uno "funciona" por azar. Con suficientes intentos, siempre aparece un falso positivo.
- **Fuga de datos (data leakage):** que información del conjunto de prueba se filtre al entrenamiento (por ejemplo, normalizar con la media de todo el dataset).
- **Ignorar la estructura temporal:** en datos financieros, mezclar aleatoriamente pasado y futuro rompe la validez. Hay que validar respetando el orden temporal.

IDEA CLAVE La regla de oro: la **matriz de confusión y el AUC** cuentan la verdad que la exactitud esconde. Si solo el 3 % de los clientes cae en mora, un modelo que dice "nadie cae" acierta el 97 %... y es completamente inútil. Por eso se miran precisión, recall y AUC, y se elige el umbral de corte según el costo real de un falso positivo (rechazar a un buen cliente) frente al de un falso negativo (aprobar a uno que no paga).

El backtest overfitting es la principal causa de estrategias que fallan en producción. La solución no es más datos ni modelos más complejos: es rigor en la validación y honestidad sobre lo que el modelo realmente sabe.

— **Marcos López de Prado.** *Cornell / ADIA*

Voces de referencia

El flujo real de un proyecto de ML es 80 % preparación de datos y validación honesta, 20 % modelo. El algoritmo de moda importa mucho menos que la disciplina del proceso.

— **Aurélien Géron.** *Hands-On Machine Learning*

En finanzas, validar mal es peor que no validar: da falsa confianza. El backtest overfitting es la principal causa de estrategias que fallan en producción.

— **Marcos López de Prado.** *Cornell / ADIA*

Existe un compromiso ineludible entre sesgo y varianza: modelos muy flexibles reducen el sesgo pero disparan la varianza. El arte está en el punto medio.

— Trevor Hastie & Robert Tibshirani. *The Elements of Statistical Learning*

CASO PRÁCTICO

Scoring de riesgo crediticio de la cartera

Maderas del Litoral S.A. — ¿a quién le vendo a crédito?

Maderas del Litoral vende a plazo a corralones y constructoras. La mora ata capital de trabajo (asignatura 2.4) y a veces se vuelve incobrable. El área comercial decide a ojo a quién dar crédito y con qué límite.

El consultor propone un **modelo de scoring**: una regresión logística que, a partir de unas pocas variables por cliente (antigüedad, utilización del límite, atrasos recientes, exposición relativa), estima la probabilidad de default y sugiere aprobar, revisar o rechazar. Se entrena, se evalúa con la matriz de confusión y —clave— se explica: cada rechazo tiene un porqué.

El entregable respeta la regla del programa: un modelo que el directorio no entiende no se aprueba.

Coefficientes del modelo (logit) y umbrales

Elemento	Valor
Intercepto (b_0)	-1,50
Antigüedad del cliente (años)	-0,30
Utilización del límite	2,50
Atrasos recientes (cantidad)	1,20
Exposición relativa	1,00
Umbral “Revisar”	PD > 30%
Umbral “Rechazar”	PD > 55%

Consigna

1. ¿Cuál es la probabilidad de default (PD) de cada cliente según el modelo?
2. ¿Qué decisión (aprobar/revisar/rechazar) sugiere cada PD?

3. ¿Cuál es la exactitud del modelo contra la mora efectiva observada (matriz de confusión)?
4. ¿Por qué la interpretabilidad del modelo es condición para usarlo en la decisión de crédito?

Metodología de resolución

1 Puntuar (logit)

$z = X\beta + b_0$ para cada cliente (MMULT de la matriz de features por los coeficientes).

2 Convertir a PD

$PD = 1/(1+e^{-z})$ (función sigmoide).

3 Decidir

Aplicar los umbrales de negocio (aprobar/revisar/rechazar).

4 Evaluar

Matriz de confusión y exactitud contra la mora observada.

5 Explicar

Mostrar el aporte de cada variable a la decisión.

Resolución numérica El caso se desarrolla íntegramente en el **Excel dinámico** de la asignatura (matrices dinámicas, sin arrastrar fórmulas). El presente PDF fija el marco conceptual, la metodología y el criterio de interpretación.

EJERCICIO ADICIONAL

Puntuar un cliente con la regresión logística

Aplicá el modelo de scoring del caso a un cliente concreto y decidí si aprobar, revisar o rechazar.

Cliente y modelo

Elemento	Valor
Intercepto (b_0)	-1,50
Antigüedad (coef -0,30)	3 años
Utilización del límite (coef 2,50)	0,80

Elemento	Valor
Atrasos recientes (coef 1,20)	1
Exposición relativa (coef 1,00)	0,40
Umbral Revisar / Rechazar	PD > 30% / 55%

Consigna

1. ¿Cuál es el score z?
2. ¿Cuál es la PD y qué decisión sugiere?

Solución

SCORE Z

$$z = -1,5 + (-0,3 \times 3) + (2,5 \times 0,8) + (1,2 \times 1) + (1,0 \times 0,4) = -1,5 - 0,9 + 2,0 + 1,2 + 0,4 = 1,2$$

PROBABILIDAD DE DEFAULT

$$PD = 1 / (1 + e^{-1,2}) = 1 / (1 + 0,301) = 0,769 \rightarrow 76,9\%$$

IDEA CLAVE PD $\approx$ 77 % > 55 % $\rightarrow$ **RECHAZAR**. Pesan la alta utilización del límite (0,80) y el atraso reciente. La decisión es explicable variable por variable, condición para usarla en crédito.

Bibliografía nuclear

- Géron, A. — *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*
- Hastie, T., Tibshirani, R. & Friedman, J. — *The Elements of Statistical Learning*
- López de Prado, M. — *Advances in Financial Machine Learning*
- James, Witten, Hastie & Tibshirani — *An Introduction to Statistical Learning*
- Goodfellow, Bengio & Courville — *Deep Learning*