



CONSULTING

Anthropic (MCP) · Russell & Norvig · Chip Huyen

Asignatura 3.4

Ingeniería de Agentes de Inteligencia Artificial para la Función Financiera

*Diseñar, construir y gobernar agentes de inteligencia artificial para la función financiera:
un modelo de lenguaje que razona, usa herramientas (el servidor MCP de la 1.2) y actúa
bajo guardarraíles, con el humano en el bucle y auditoría de cada paso.*

PREDICTIVA

36 h · 12 teóricas / 24 prácticas

Cuatrimestre 3

Correlativas: 1.2 y 3.2 · Tercer cuatrimestre

Objetivos de aprendizaje

- Comprender qué es un agente: modelo + herramientas + memoria + bucle de razonamiento y acción.
- Conectar el agente a las herramientas del ERP mediante el servidor MCP de la asignatura 1.2.
- Diseñar guardarraíles, puntos de control humano y registro de auditoría.
- Evaluar el agente y gestionar sus riesgos (alucinación, sobre-automatización, gobernanza).

01 Qué es un agente

Un agente no es un chatbot: es un sistema que percibe, razona, decide qué herramienta usar, actúa y observa el resultado, en un bucle, hasta cumplir un objetivo.

ANATOMÍA DE UN AGENTE

Agente = Modelo (razonamiento) + Herramientas (acción) +
Memoria (contexto) + Bucle (percibir → decidir → actuar →
observar)

La diferencia con un simple prompt: el agente elige acciones, las ejecuta contra el mundo real y reacciona a lo que observa.

En la tradición de Russell y Norvig, un **agente racional** percibe su entorno y actúa para maximizar su objetivo. Un agente de IA moderno usa un modelo de lenguaje como motor de razonamiento y **herramientas** como manos: consultar el ERP, calcular en la planilla, enviar un correo, generar un informe.

IDEA CLAVE La conexión con el programa: las **herramientas del agente son el servidor MCP** de la asignatura 1.2. El agente no accede a la base directamente; llama a herramientas auditadas de sólo lectura. La trazabilidad del dato sobrevive incluso cuando quien consulta es una IA.

02 Patrones de diseño de agentes

No todo problema necesita un agente autónomo. La ingeniería consiste en elegir el patrón más simple que funcione.

- **Razonar y actuar (ReAct):** el agente alterna pensamiento y acción, decidiendo el próximo paso según lo observado.
- **Planificación:** descompone un objetivo en subtarefas antes de ejecutarlas.
- **Reflexión:** el agente critica su propia salida y la corrige (el auditor escéptico incorporado).
- **Multi-agente:** varios agentes especializados (uno extrae, otro modela, otro redacta) coordinados.

Empezá con la solución más simple posible y agregá complejidad solo cuando demuestre su valor. Muchos problemas se resuelven con un flujo de trabajo bien definido, no con un agente autónomo.

— **Documentación de agentes (Anthropic).** *Building effective agents*

ATENCIÓN La autonomía tiene un costo: cuanto más decide el agente por su cuenta, más difícil es predecir y auditar su comportamiento. En finanzas, la autonomía se concede de a poco y sobre acciones reversibles.

03 Guardarraíles, humano en el bucle y auditoría

En la función financiera, un agente sin controles es un pasivo. El gobierno se diseña junto con el agente, no después.

- **Sólo lectura por defecto:** el agente consulta y propone; las acciones que mueven dinero o modifican registros pasan por aprobación humana.
- **Humano en el bucle** en los puntos críticos: aprobar un pago, enviar un informe al directorio, rechazar un crédito.
- **Registro de auditoría de cada paso:** qué herramienta llamó, con qué parámetros, qué obtuvo y qué decidió — el mismo principio del servidor MCP.
- **Límites y permisos** explícitos: qué puede y qué no puede hacer el agente.

La confiabilidad de un sistema de IA no viene del modelo, sino de la ingeniería alrededor: evaluación, monitoreo, guardarraíles y la posibilidad de intervención humana.

— **Chip Huyen.** *AI Engineering*

04 Evaluación, riesgos y la decisión de automatizar

No todo se debe automatizar. La decisión es económica y de riesgo, no tecnológica.

- **Evaluación:** conjuntos de prueba con casos conocidos; medir acierto, no impresión. Un agente que “parece” funcionar no es un agente evaluado.
- **Alucinación:** el modelo puede inventar con seguridad; por eso toda cifra debe ser trazable a una herramienta, no generada por el modelo.
- **Sobre-automatización:** automatizar una tarea mal entendida multiplica el error. Primero se entiende y ordena el proceso, después se automatiza.
- **Gobernanza:** responsabilidad, confidencialidad (Ley 25.326) y la regla de oro: la responsabilidad final es humana.

IDEA CLAVE La decisión de qué automatizar se prioriza por **retorno y factibilidad**: tareas frecuentes, repetitivas, de reglas claras y bajo riesgo primero. Una tarea infrecuente, ambigua y de alto riesgo es la última candidata, por más “automatizable” que parezca.

05 Patrones de diseño: del más simple al más complejo

La ingeniería de agentes consiste en elegir el patrón más simple que resuelva el problema. Agregar autonomía sin necesidad es sumar riesgo sin beneficio.

Patrones de agentes, de menor a mayor complejidad

Patrón	Qué hace	Cuándo usarlo
Flujo de trabajo	Pasos predefinidos, el modelo completa cada uno	Proceso conocido y estable
ReAct	Alterna razonamiento y acción según lo observado	La tarea requiere decidir el próximo paso
Planificación	Descompone el objetivo en subtareas antes de ejecutar	Objetivos complejos y multi-paso
Reflexión	El agente critica y corrige su propia salida	Cuando la calidad importa más que la velocidad
Multi-agente	Agentes especializados coordinados	Tareas que se benefician de la división del trabajo

Empezá con la solución más simple posible y agregá complejidad solo cuando demuestre su valor. Muchos problemas se resuelven con un flujo de trabajo bien definido, no con un agente autónomo.

La mayoría de las aplicaciones exitosas de agentes usan patrones simples y componibles, no autonomía máxima. La complejidad debe justificarse por el valor que aporta, no por lo impresionante que suena.

— **Documentación de agentes (Anthropic).** *Building effective agents*

06 Gobierno del agente financiero

En la función financiera, un agente sin controles es un pasivo. El gobierno se diseña junto con el agente, no después.

- **Sólo lectura por defecto:** el agente consulta y propone; las acciones que mueven dinero o modifican registros pasan por aprobación humana.
- **Humano en el bucle** en los puntos críticos: aprobar un pago, enviar un informe al directorio, rechazar un crédito.
- **Registro de auditoría de cada paso:** qué herramienta llamó, con qué parámetros, qué obtuvo y qué decidió —el mismo principio del servidor MCP de la 1.2—.
- **Autonomía gradual:** se concede primero sobre acciones reversibles y de bajo impacto; lo crítico e irreversible mantiene control humano hasta ganar confianza.

ATENCIÓN El riesgo de la **alucinación** obliga a una regla estricta: toda cifra que el agente reporta debe ser **trazable a una herramienta auditada**, no generada por el modelo. Un agente financiero no "recuerda" saldos ni "estima" cifras: las consulta al servidor MCP de sólo lectura y las cita. La responsabilidad final, siempre, es humana.

La confiabilidad de un sistema de IA no viene del modelo, sino de la ingeniería alrededor: evaluación con casos conocidos, monitoreo, guardarraíles y la posibilidad de intervención humana. Sin eso, no hay ingeniería, solo demostraciones.

— **Chip Huyen.** *AI Engineering*

07 Evaluar un agente: medir, no impresionarse

Un agente que "parece" funcionar no es un agente evaluado. La ingeniería empieza por saber cómo se mide el acierto.

La **evaluación** de un agente se hace contra un conjunto de casos con respuesta conocida: se mide el

acierto, no la impresión que da la demo. Antes de preguntar "¿qué modelo uso?", la pregunta correcta es "¿cómo sé si funciona?". Sin evaluación no hay ingeniería, solo demostraciones.

- **Conjuntos de prueba:** casos representativos con la respuesta correcta, para medir acierto de forma objetiva.
- **Métricas por tarea:** exactitud en extracción de datos, calidad de un informe, corrección de un cálculo —cada tarea tiene su métrica—.
- **Monitoreo en producción:** los agentes se degradan; hay que vigilar el desempeño real, no solo el del laboratorio.
- **Detección de alucinación:** verificar que cada cifra reportada sea trazable a una herramienta, no generada por el modelo.

La diferencia entre un prototipo impresionante y un sistema confiable está en la evaluación. Cualquiera puede construir una demo que funciona una vez; la ingeniería consiste en saber, con evidencia, que funciona el 99 % de las veces —y qué pasa el 1 % restante—.

— Chip Huyen. *AI Engineering*

08 La decisión de automatizar es económica, no tecnológica

No todo se debe automatizar. La pregunta no es "¿se puede?", sino "¿conviene?".

La priorización de qué automatizar se ordena por **retorno y factibilidad**: tareas frecuentes, repetitivas, de reglas claras y bajo riesgo primero. Una tarea infrecuente, ambigua y de alto riesgo —como la recomendación final al directorio— es la última candidata, por más "automatizable" que parezca, porque el costo de un error supera con creces el ahorro.

EL AHORRO POTENCIAL PONDERADO

$$\text{Ahorro} = \text{Horas/año} \times \text{Costo/hora} \times \text{Factibilidad} \times (1 - \text{Riesgo})$$

Ponderar por factibilidad y riesgo evita automatizar lo que no conviene aunque técnicamente se pueda.

ATENCIÓN La **sobre-automatización** es un riesgo real: automatizar un proceso mal entendido multiplica el error en vez de eliminarlo. La secuencia correcta es entender y ordenar el proceso primero, automatizarlo después. Y la regla de oro permanece: la responsabilidad final es humana, siempre. El agente construye y propone; la persona decide y responde.

La automatización más valiosa no es la más ambiciosa, sino la más apropiada: la que resuelve un problema real, frecuente y bien entendido, con la mínima complejidad necesaria y el gobierno adecuado.

— **Documentación de agentes (Anthropic).** *Building effective agents*

09 La arquitectura multi-agente de la función financiera

El diseño que propone el programa: un agente especialista por dominio, un agente de contexto que provee la verdad de los datos, y un agente integrador que sintetiza y eleva la recomendación al humano que decide.

Un solo agente que "haga todo el análisis financiero" es una mala arquitectura por la misma razón por la que una herramienta MCP que "devuelve todo" es una mala herramienta: **pierde especificidad, no se puede auditar por partes y falla de manera opaca**. La alternativa es un sistema de agentes especializados, cada uno con su dominio acotado, sus herramientas y su criterio de calidad.

Los agentes especialistas, uno por dominio


Agente	Dominio	Asignaturas que encarna	Entrega
Contable	Depuración y normalización	1.1	Estado analítico, memorando de ajustes
Valor	NOPAT, capital, ROIC, EVA	1.4, 2.1	Tablero de generación de valor
Capital de trabajo	CCE, ABC/XYZ, cobranzas	2.4	Capital liberable y su efecto en EVA
Riesgo	Insolvencia, calidad de ganancias	2.2	Z", Merton, Beneish, calificación sintética
Costo del capital	Ke, Kd, WACC	3.1	WACC documentado con sensibilidad
Proyección	Escenarios y Monte Carlo	3.3	Distribución de resultados y métricas de riesgo
Valuación	DCF, APV, descuentos	4.1	Rango de valor con supuestos declarados
Liquidez	DSCR, covenants, DAF-E	4.3	Días de autonomía y alertas

Cada agente es un especialista con una asignatura del programa como cuerpo de conocimiento, herramientas propias y un entregable definido y verificable.

Sobre ellos operan dos agentes de naturaleza distinta:

- **El agente de contexto.** No analiza: **provee la verdad.** Es el único que habla con el servidor MCP de sólo lectura (asignatura 1.2) y con la capa semántica. Su función es que todos los especialistas trabajen sobre **el mismo dato, con la misma definición.** Sin él, cada agente calcularía su propio "capital invertido" y las conclusiones no serían comparables.
- **El agente integrador (CEO).** No calcula: **sintetiza, detecta contradicciones y prioriza.** Recibe los entregables de los especialistas, verifica su coherencia, resuelve las tensiones entre ellos y produce una recomendación única y jerarquizada para el humano que decide.

El flujo de la arquitectura



El contexto alimenta a todos; los especialistas trabajan en paralelo sobre la misma verdad; el integrador sintetiza; el humano decide y firma.

10 El agente integrador: sintetizar y detectar contradicciones

Es el componente más delicado del sistema y el que más valor agrega, porque hace algo que ningún especialista puede hacer: mirar el conjunto.

La función del agente integrador no es promediar opiniones sino **detectar las tensiones que solo aparecen al cruzar dominios.** Son exactamente las tensiones que atraviesan todo el programa:

Contradicciones que solo el integrador puede detectar

Agente A dice	Agente B dice	Tensión que el integrador debe resolver
Valor: "crea valor, EVA positivo"	Liquidez: "DAF-E < CCE"	Rentable pero al borde de la iliquidez (4.3)
Riesgo: "Altman en zona segura"	Liquidez: "DSCR ajustado"	Solvente pero sin caja: distinguir ambas cosas
Proyección: "crecimiento del 12 %"	Costo capital: "RONIC < WACC"	Crece destruyendo valor (4.2)
Contable: "EBITDA 5.250"	Riesgo: "M-Score elevado"	La calidad del EBITDA está en duda

Agente A dice	Agente B dice	Tensión que el integrador debe resolver
Capital de trabajo: "liberar 4.500"	Valuación: "vale 12.800"	Cuantificar el efecto de la mejora sobre el valor

Cada fila es una situación real del caso Maderas del Litoral. Ningún especialista aislado la ve; el integrador sí, porque su función es precisamente cruzar dominios.

El protocolo del agente integrador

1 Recibir y validar

Verificar que cada especialista entregó lo suyo con los supuestos declarados y trazables a herramientas.

2 Verificar coherencia numérica

Que el capital invertido del agente de valor sea el mismo que usó el de costo del capital; que el EBITDA sea el mismo en todos. La reconciliación es obligatoria.

3 Detectar contradicciones

Cruzar conclusiones por pares y marcar las tensiones (la tabla de arriba).

4 Priorizar por impacto en el valor

Ordenar los hallazgos por su efecto cuantificado sobre el EVA, no por el orden en que llegaron.

5 Elevar al humano

Recomendación única, jerarquizada, con las contradicciones explicitadas y las decisiones que requieren juicio humano señaladas como tales.

ATENCIÓN El nombre "agente CEO" es una metáfora de arquitectura, no una descripción de autoridad. **El agente integrador no decide: prepara la decisión.** Sintetiza, ordena, señala tensiones y recomienda. La decisión —y la responsabilidad— es del humano. Confundir la metáfora con la función es el camino más corto a delegar en un sistema aquello que ningún sistema debe asumir.

11 Gobierno de la arquitectura multi-agente

Un sistema de ocho agentes autónomos sin gobierno es ocho veces más riesgoso que uno. El diseño de control crece con la cantidad de agentes, no al revés.

- **Una sola fuente de verdad.** Solo el agente de contexto habla con el ERP, y lo hace por el servidor MCP de sólo lectura. Ningún especialista consulta datos por su cuenta. Esto elimina de raíz la

posibilidad de que dos agentes trabajen sobre cifras distintas.

- **Trazabilidad extremo a extremo.** Cada número del informe final debe poder rastrearse: qué agente lo produjo, con qué herramienta, sobre qué dato y con qué supuestos. Si un número no es trazable, no entra al informe.
- **Supuestos explícitos y versionados.** Cada agente declara los suyos; el integrador los consolida en un anexo. Sin eso, es imposible auditar el trabajo o repetirlo.
- **Puntos de control humano.** Antes de la recomendación final, siempre. Y ante cualquier acción que mueva dinero, modifique registros o salga hacia terceros.
- **Registro de auditoría completo.** De cada llamada de cada agente: herramienta, parámetros, resultado, momento y decisión tomada.

IDEA CLAVE La ventaja decisiva de esta arquitectura frente al agente monolítico es la **auditabilidad por partes**. Si el resultado final está mal, se puede identificar exactamente qué especialista falló y por qué —igual que en un equipo humano de consultoría—. Un agente único que hace todo falla de manera opaca: se sabe que el resultado está mal, pero no dónde se rompió el razonamiento.

ATENCIÓN El riesgo específico de los sistemas multi-agente: **la propagación de errores**. Si el agente contable entrega un capital invertido mal calculado, los agentes de valor, costo del capital y valuación construyen todos sobre ese error, y el informe final es coherente internamente y equivocado por completo. Por eso la verificación de coherencia del integrador y la conciliación contra el balance publicado (asignatura 1.2) no son opcionales: son el cortafuegos del sistema.

Voces de referencia

Distinguí flujos de trabajo (pasos predefinidos) de agentes (el modelo dirige el proceso). La mayoría de las aplicaciones exitosas usan patrones simples y componibles, no autonomía máxima.

— **Documentación de agentes (Anthropic).** *Building effective agents*

Un agente racional actúa para maximizar su medida de desempeño dada la información disponible. El diseño empieza por definir con precisión ese objetivo y ese entorno.

— **Stuart Russell & Peter Norvig.** *Artificial Intelligence: A Modern Approach*

Antes de preguntar “¿qué modelo uso?”, preguntá “¿cómo sé si funciona?”. Sin evaluación, no hay ingeniería, solo demostraciones.

— **Chip Huyen.** *AI Engineering*

CASO PRÁCTICO

¿Qué le conviene automatizar a la función financiera?

Maderas del Litoral S.A. — el agente financiero

Con el servidor MCP ya construido (asignatura 1.2), Maderas del Litoral podría poner un agente de IA a trabajar sobre su función financiera. Pero, ¿en qué? La contadora hace muchas tareas: concilia bancos, arma el reporte de cobranzas, calcula el CCE, prepara el tablero de valor, responde consultas del directorio.

El consultor no automatiza por moda: prioriza. Para cada tarea estima la frecuencia, las horas que consume, su factibilidad de automatización y su riesgo, y calcula el ahorro potencial ponderado. Las tareas frecuentes, repetitivas y de bajo riesgo (conciliación, reporte de cobranzas) encabezan la lista; las de alto juicio y riesgo (recomendación al directorio) quedan con el humano al frente y la IA como apoyo.

El entregable es un plan de automatización priorizado, no un agente que hace todo.

Tareas de la función financiera

Tarea	Veces/mes	Horas c/u	Factib.	Riesgo
Conciliación bancaria	20	1,5	0,90	0,15
Reporte de cobranzas	4	3,0	0,85	0,20
Cálculo del CCE y tablero	1	6,0	0,80	0,25
Respuesta a consultas del directorio	8	1,0	0,40	0,60
Recomendación de crédito	15	0,8	0,55	0,50

Consigna

1. ¿Cuál es el ahorro potencial ponderado (por factibilidad y riesgo) de automatizar cada tarea?

2. ¿Cómo queda el ranking de prioridad de automatización?
3. ¿Qué tareas deben mantener al humano en el bucle y por qué?
4. ¿Por qué las herramientas del agente deben ser el servidor MCP de sólo lectura y no acceso directo a la base?

Metodología de resolución

1 Estimar el volumen

Horas/año = veces/mes × 12 × horas por vez.

2 Ponderar

Ahorro ponderado = horas/año × costo/hora × factibilidad × (1 – riesgo).

3 Priorizar

Ordenar por ahorro ponderado (SORTBY): primero lo frecuente, repetible y de bajo riesgo.

4 Gobernar

Definir puntos de control humano y auditoría para las tareas de mayor riesgo.

5 Conectar

Las herramientas del agente = servidor MCP de sólo lectura, con trazabilidad.

Resolución numérica El caso se desarrolla íntegramente en el **Excel dinámico** de la asignatura (matrices dinámicas, sin arrastrar fórmulas). El presente PDF fija el marco conceptual, la metodología y el criterio de interpretación.

EJERCICIO ADICIONAL

¿Conviene automatizar esta tarea?

Estimá el ahorro potencial ponderado de automatizar una tarea de la función financiera y decidí si es candidata.

Tarea: conciliación bancaria

Parámetro	Valor
Veces por mes	20

Parámetro	Valor
Horas por vez	1,5
Costo por hora	8 miles \$
Factibilidad	0,90
Riesgo	0,15
Umbral “humano en el bucle”	riesgo > 0,40

Consigna

1. ¿Cuántas horas/año consume y cuál es el ahorro potencial ponderado?
2. ¿Es automatizable o requiere humano en el bucle?

Solución

HORAS/AÑO Y AHORRO

$$\text{Horas/año} = 20 \times 12 \times 1,5 = 360 \quad \cdot \quad \text{Ahorro} = 360 \times 8 \times 0,90 \times (1 - 0,15) = 2.203$$

IDEA CLAVE Ahorro potencial ponderado ≈ **2.203** (miles) al año sobre 360 horas. Con riesgo $0,15 < 0,40$, la tarea es **automatizable**: frecuente, repetible y de bajo riesgo — candidata ideal, con las herramientas de sólo lectura del servidor MCP.

Bibliografía nuclear

- Anthropic — *Building effective agents y Model Context Protocol* (2024–2026)
- Russell, S. & Norvig, P. — *Artificial Intelligence: A Modern Approach*
- Huyen, C. — *AI Engineering*
- Weng, L. — *LLM-powered Autonomous Agents* (nota técnica)
- Ley 25.326 de Protección de los Datos Personales (Argentina)